

# Makine Öğrenmesi Algoritmaları ile Twitter'da Sahte Haber Tespiti

Batuhan Battal, Başar Yıldırım, Ömer Faruk Dinçaslan  
Gülay Çiçek

Yazılım Mühendisliği Bölümü, Mühendislik-Mimarlık Fakültesi  
İstanbul Beykent Üniversitesi, Sariyer, İstanbul, TÜRKİYE

**Özet–** Günümüzde teknolojinin ilerlemesiyle birlikte haber kaynaklarının kullanımı da büyük bir evrim geçirmiştir. Haber kaynakları, geçmişten günümüze dergilerden radyolara, gazetelerden televizyonlara kadar uzanarak sürekli olarak gelişim göstermiştir. Habere ulaşmanın bu kadar kolay hale gelmesi, toplumun sahte haberlere daha fazla dikkat etmesine neden olmuştur.

Sahte haberler, teknolojinin gelişmesiyle birlikte daha geniş kitlelere ulaşabilen sosyal medya gibi haber kaynakları tarafından toplumu etkileme yeteneğine sahiptir. Bu durumlarla birlikte, toplumda ve sosyal medyada sahte haberleri tespit etme ve önleme çalışmaları başlamıştır. Birçok sosyal medya platformunda, sahte haberleri tespit etmek için uzmanlar görev almaktadır ve bu konuda çalışmaktadırlar.

Bu çalışmada kullanılan veriler iki kategoriye ayrılmıştır: gerçek ve sahte. Gerçek kategorisinde dört öznitelik bulunmaktadır: title, text, subject, date. Title özniteliği yaklaşık 21.000 farklı değere sahiptir. Sahte kategorisinde de aynı şekilde dört öznitelik bulunmaktadır. Bu çalışma, gerçek ve sahte kategorilerinde toplamda 42.000 veri üzerinde gerçekleştirilmiştir.

Çalışmamızda türkçe dili üzerinde makine öğrenmesi algoritmalarından denetimli ve denetimsiz olanlar kullanılarak Twitter platformunda sahte haber tespiti yapılmıştır ve sonuçları gözlenmiştir. Denetimli öğrenme algoritmalarından K-En Yakın Komşu Sınıflandırması doğruluk sonucu 0.67, Destek Vektör Makinaları Sınıflandırması doğruluk sonucu 0.52, Rastgele Orman Sınıflandırması doğruluk sonucu 0.76, Naive Bayes Algoritması doğruluk sonucu 0.58, Gradyan Arttırıcı Algoritması 0.72. Karar Ağacı Algoritması doğruluk sonucu 0.99, Lojistik Regresyon Sınıflandırması doğruluk sonucu 0.70 olarak gözlemlenmiştir. Sonuç olarak Rastgele Orman Sınıflandırması doğruluk sonucu 0.76 ile en yüksek performansı göstermiştir.

**Anahtar Kelimeler:** Sahte Haber Tespiti, Sosyal Medyada Haber, Sınıflandırma.

**Abstract—**Nowadays, the use of news sources has developed considerably along with technology. From the past to the present, news sources have developed day by day, from magazines to radio and from newspapers to television... The society, which has adopted that it is so easy to access news, has started to notice fake news more and more as

the use of technology has increased. The times when fake news is in question are sometimes used for interaction and sometimes even for manipulation by politicians. At this point in technology, news sources such as social media, which can reach millions in seconds, are quite sufficient to manipulate society. Within these events, studies on fake news detection and fake news prevention in society and social media have started. In most of social media application, there are experts for the detection of fake news and they work for detection. The data used in this study is divided into 2 categories. These categories are named as fake and real. There are 4 attributes in the real category. These are title, text, subject, date attributes. Title has approximately 21,000 unique values. There are 4 attributes in the fake category in the same way. These are title, text, subject, date attributes. Title has approximately 21,000 unique values. The study was conducted on a total of 42,000 data in the real and fake categories. In this study, supervised and unsupervised machine learning algorithms are used in the Turkish language to detect fake news on Twitter and the results are analyzed. Among the supervised learning algorithms, K-Nearest Neighbor Classification accuracy result is 0.67, Support Vector Machine Classification accuracy result is 0.52, Random Forest Classification accuracy result is 0.76, Naive Bayes Algorithm accuracy result is 0.58, Gradient Boosting Algorithm accuracy result is 0.58, Gradient Boosting Algorithm accuracy result is 0.72, Decision Tree Algorithm accuracy result is 0.99, Logistic Regression Classification accuracy result is 0.70. As a result, Random Forest Classification showed the highest performance with an accuracy of 0.76.


**Index Terms—**Keywords : Fake News Detection, News on Social Media, Twitter.

## I. GİRİŞ

İnsanlık bütün bir tarihi süreç boyunca çeşitli iletişim ve haberleşme araçlarına gereksinim duymuş, sürekli olarak bu araçları geliştirmiş ve bu gelişmeler toplumları daha yakın hale getirmiştir. Modern çağın başlangıcından itibaren insanlar çok fazla gelişmeye tanık olmuştur, geçmişte bu olaylar halk arasında söylentiler ile yayılmış ve bu durum daha güvenilir ve kapsamlı bir şekilde insanlara ulaştırma gereksinimlerini doğurmuştur. Bu iletişim araçlarına örnek olarak; dumanla haberleşme, posta güvercinleri tarzı iletişim araçları kimi zaman savaş gibi çeşitli nedenlerden kullanılmış olsa da bu ilkel haberleşme araçları mektuplaşma, gazete, dergi ve bunların yanı sıra telgraf, radyo ve televizyon gibi daha modern teknolojik aletlere evrilmiştir. Özellikle teknolojinin modern zamanlarında bilginin de aynı paralelde yayılması beraberinde yanlış ve manipüle edilmiş bilgilerin hızla yayılmasına neden olmuştur. Dolayısıyla bu araçlar ve

Fig. 1: Sahte Trendlerin Gündeme Etkileri

[1]



gereksinimler beraberinde bilgi kirliliğini de getirmiştir. Günümüz dünyasında doğru bilgiye ulaşım zor olduğu gibi geçmişte de yanlış bilgileri tespit edip doğruya çevirmek oldukça zor olmuştur [2]. Fakat bu zorluk geçmişe nazaran şu an daha büyük bir yoğunluğa sahiptir. Çünkü tek taraflı haber kaynakları belli bir bakış açısından yazıldığı için insanlar haberi ilk aldıkları andan itibaren büyük bir manipülasyona uğratıp bu kirli bilgiyi insanlara empoze etmiştir. Bazı zamanlarda devlet büyükleri ya da kurumlar tarafından bu durum bilinçli olarak kullanılarak halkı bir bakıma kötü amaçları için kullanmıştır [3]. Buna örnek olarak: Milattan sonra 500'li yıllarda Bizans'da yaşamış olan Prokopius bir tarihçidir, resmî tarih yazılarıyla İmparator Justinianous'un dikkatini çekmeyi başardıktan bir müddet sonra imparatorun itibarını lekelemek amacıyla "anektod" adıyla bilinen şüpheli bilgileri üretmiş ve ölene kadar bu sırrı saklamıştır. Pietro Aretino 1522'deki papalık seçimlerini manipüle etmek için adaylar hakkında garip soneler yazmıştır. Roma'da Navona Meydanı'nda bulunan Pasquino olarak bilinen heykelin yakınlarında halka bu soneleri söylemeye başlamıştır. "Pasquinade" (taşlama) tabiri, daha sonrasında, halka mal olmuş kişiler hakkındaki ahlaksız ve çoğunlukla da yanlış haberler için söylenen genel bir kullanıma evrilmiştir [4]. Günümüzde sosyal medya platformları, haber alma ve paylaşma konusunda önemli bir rol oynamaktadır. Ancak, bu platformlarda ortaya çıkan sahte trendler, kullanıcıları yanıltabilir ve geniş çaplı etkiler doğurabilir. Twitter, özellikle hızlı bilgi akışı ile bilinen bir platform olup, sahte trendlerin bu ağ üzerinde nasıl oluştuğu ve yayıldığı konusunda dikkat çekici bir örnek sunmaktadır. Şekil 1. de ki tabloda da , sahte trendlerin gündeme etkilerini aylara oranlarını


görmek mümkündür.

Bu gelişmeler ışığında sadece yanlış bilginin manipülatif etkisi artmakla kalmamıştır aynı zamanda doğru bilginin de yayılımı hızla artmıştır. İnsanların ilgi alanları daha fazla genişlemiş ve sadece yaşadıkları bölgeyle kalmayıp dünya hakkında fikirleri olmaya başlamıştır. Böylece bilime duyulan ilgi ve isteğin artmasıyla birlikte zamanla teknoloji de her zaman olduğu gibi yerinde saymamaktadır. Bu ilgi alanlarının artmasıyla beraber teknolojik gelişmeler kat ve kat artmış durumdadır. Bu olaylar dünya genelinde hızla yayılmaya başlamıştır. Özellikle teknoloji sektörüne duyulan bu ilgi sonrasında yeni icatlar da pek tabii ki insanların hayatlarına girmeye başlamıştır. Bu icatların başında elbette bilgisayar ve cep telefonu geliyor. Bu araçların da halkın hayatlarına girmesiyle birlikte elbette bilgi artık geçmişe nazaran daha akışkan hale gelmiştir. İnsanlar artık ceplerinde bir haber makinesi taşımakta ve bilgiye istedikleri zaman ulaşmaya başlamaktadırlar.

Günümüzde cep telefonlarıyla birlikte dijital medya diye adlandırılan bir haberleşme platformu ortaya çıkmıştır. Dolayısıyla kullanıcı miktarı da artmaktadır. Bilgiye erişim daha önce hiç olmadığı kadar hızlı ve geniş kapsamlı olmuştur. Bu geniş kapsamlı kaynaklar arasında, internet ve sosyal medya platformlarının kolay olan yaygın kullanımıyla birlikte bilgi paylaşımını kolaylaştırmakta, aynı zamanda yanıltıcı içeriklerin de hızla yayılmasına olanak tanımaktadır. Bu durum sahte haberlerin çok daha rahat bir şekilde yayılmasına olanak tanıyan bir ortam ortaya çıkarmıştır ve böylelikle kullanıcının güvenilir ve doğru bilgiye ulaşması sanılanın aksine daha zorlaşmıştır.

Fig. 2: Sosyal Mecralarda Sahte Haber Dağılımı

[5]




Bu ortaya çıkan duruma bakıldığında kullanıcıların günlük yaşamlarını şekillendiren bu bilgi akışında doğru ve güvenilir kaynaklara ulaşma konusundaki zorlukları, sahte haberlerin yayılma potansiyelini artırmaktadır ve gerçek ya da sahte haberler arasındaki ayrımı yapmak giderek zorlaşmaktadır. Bu olayın temelinde, yapılan bu sahte haberlerin tespitleri sadece bir bilgi güvenliği meselesi olmakla kalmayıp, aynı zamanda demokratik ve ahlaklı bir toplumun sağlıklı işleyişi bakımından da çok kritik bir öneme sahiptir. Çünkü sahte haberler, toplumların düşünce biçimini etkileyebilir, kamusal güveni sarsabilir ve hatta siyasi kararları şekillendirebilir. Bunları takiben sahte haberleri tespit etmek ve gerçek bilgiden ayırt etmek günümüzün büyük bir zorluğu haline gelmiştir. Geçmişte de olduğu gibi günümüzde de fazlaca halkı yanıltmaya yönelik manipülatif hareketler ve siyasi taktikler gerçekleşmiştir. Bu bazen halkın iyiliğine olsa da bazen de kötü sonuçlar ortaya çıkarabilir [6]. Bu manipülatif olaylara ilişkin 2017 yılında ABD’de gerçekleşen Amerika başkanına yönelik sahte haber paylaşımı örnek verilmiştir. “Yanlış bilginin uzun tarihinde, sahte habere ilişkin son dönemlerdeki gelişmeler özel bir yer tutuyor, özellikle ABD Başkanı Donald Trump’ın özel danışmanı Kellyanne Conway, Müslüman ülkelere yönelik seyahat yasağını savunmak için Kentucky katliamını icat ederek oldukça ileri gitti. Alternatif gerçeklerin uydurulması tarihsel olarak da oldukça enderdir, ama bugünün zehirli, tadımlık yazılarının ve tweetlerin muadiline farklı tarihsel dönemlerde, hatta antik dönemlerde dahi rastlanabilir.”

Sahte Haberler, özellikle sosyal medya mecraları ve çevrimiçi haber sitesi aracılığıyla hızla yayılarak büyük bir yaygınlık kazanmaktadır. Sosyal medya algoritmalarının etkisi, duygusal içerik kullanımı, insanların kendi görüşlerini doğrulama eğilimi ve haber kaynaklarının denetim eksikliği, sahte haberlerin yayılmasını kolaylaştırmaktadır. Şekil 2. de de görüldüğü üzere sosyal medya mecralarında sahte haber dağılımı gösterilmiştir. Toplumun sosyal medyayı artık daha fazla kullanmasıyla birlikte sahte haberlerin dağılımı facebook ve twitterda oldukça artmıştır.

Dijital devrimin getirdiği bilgi çoğalması, sosyal medyanın yükselişi ve çevrimiçi haber olankalarının çok daha fazla artmasıyla birlikte, doğal olarak sahte haberlerin yayılma potansiyeli çok daha fazla artmış duruma geldi. Bu durum, bilinçli bir şekilde üretilmiş yanlış bilgilerin, bazen gerçek haberlerle neredeyse aynı hızda ve etkileşimle paylaşılmasına yol açmaktadır [7]. Bu nedenle, sahte haberleri tespit etmek ve bunlara karşı mücadele etmek, modern toplumların bilgi çağında karşılaştığı önemli bir sorun haline gelmiştir. Dolayısıyla kullanıcıların sosyal medya kullanımında daha bilinçli ve dikkatli olmaları gerekmektedir [8].

Sosyal medya platformlarının doğası gereği haber ve bilgi paylaşımlarının geniş kitlelere ulaşma hızı azımsanmayacak dereceye erişmiştir. Bu sosyal medya platformlarının kullanıcı sayıları milyonlarca insan sayısına ulaştığı için sahte haberlerin yayılma hızları özellikle instagram, twitter, youtube, facebook, tiktok gibi sosyal medya platformları üzerinde zaman geçtikçe ışık hızına ulaşmıştır. Dolayısıyla herkesin erişimi olduğu bu platformlar kullanıcı portföyünü de arttırmıştır ve kul-

Fig. 3: Kapatılan Botlar



lanıcılar artık sadece yetişkin insanları değil çocukları da kapsamaktadır. Yapılan bir araştırmaya göre; İnsanlarda yaş küçüldükçe sosyal platformların kullanımına ayrılan süre artıyor. Bu bilgi neticesinde sosyal medya kullanımının yaşla ters orantılı olduğu gözlemlenmektedir. Z kuşağı dışında her yaş grubu arasında haber almak, sosyal medyayı kullanmanın en sık belirtilen nedenidir [9].

Twitter artık yeni haber kaynağı olmuştur. Gün geçtikçe insanların haber kaynaklarına güvenleri kalmamış haberlerin neredeyse çoğunu twitterdan almaktadır. Gazetecilerin de artık sosyal medyada etkin olmasıyla birlikte artık haber dolaşımı daha da yoğun olmuştur. Bu yoğunluk bazı kişi ve kurumlar tarafından suistimal edilerek manipülatif bir hale gelmekle birlikte zamanla dezavantajlı bir durum haline dönüşmüştür. Kötü niyetli kullanıcılar tarafından yapılan sahte haberler her konuda insani faaliyetleri etkilemektedir. Bu bağlamda, haberin ana teması olan bireylerin ya da kurumların korunması ve okuyucuların güvenilir bilgiler elde etmesi açısından, sahte haberlerin belirlenmesi kritik bir konudur[10]. Bilgiye ulaşmanın hususi olmasının yanı sıra sahte haberlerin tespiti büyük bir önem arz eder, bunun faydalarından biri de okuyucunun tek bir doğruya ulaşması ve bunun yanı sıra haber sistemine olan güveninin artmasıdır. Bu sebeple, sahte haber tespit çalışmalarına başlanmadan önce sahte haberlerin daha detaylı bir şekilde incelenmesi elzemdir[11]. Bu çalışmada kullanılan veri setlerini daha iyi kategorize edilmiş bir veri seti haline getirmek için veri temizleme (gürültülü ve tutarlılığı olmayan verilerden kurtulmak), Veri bütünleşimi (farklı veri kaynaklarını bir araya getirme), veri seçimi (analiz edilecek önemli verileri belirleme) ve veri dönüşümü gibi veri madenciliği tekniklerini kullanılarak verinin madencilik için uygun

hale getirilmesi gerekmektedir. Böylelikle bu iyi kategorize edilmiş veri setleri sayesinde sahte haberlerin tespit edilmesi bizler için daha kolay olacaktır [12]. Sosyal medya platformları, iletişimi kolaylaştırmanın yanı sıra, bot hesapların yayılması ve etkileşimde bulunması gibi sorunlarla da karşı karşıya. Özellikle Twitter, gerçek ve sahte hesapları birbirinden ayırt etmek amacıyla sürekli olarak çeşitli önlemler almaktadır [13]. Bu önlemler kapsamında, kapatılan bot hesaplarının sayısı gün geçtikçe artmaktadır. Şekil 3. de de görüldüğü üzere Twitter'da kapatılan botların aylara göre oranları verilmektedir[14].

Shu ve diğer araştırmacılarının çalışmasında, Figür 4'te görüldüğü üzere geleneksel medyadaki sahte haberler ile sosyal mecralarda ki sahte haberlerin psikolojik ve sosyal yönlerini inceledikleri görülmektedir. İlk kategoriye bakıldığında, propaganda amacıyla oluşturulmuş sahte hesaplar yer alırken, ikinci kategoride kullanıcıların benzer düşüncelere sahip kişileri takip etmeleri ve bu hesapların paylaştığı haberlere güvenmeleri sonucu oluşan, sahte haber olmasına rağmen kendi ilgi alanlarına yakın haberleri alıp paylaşma eğiliminde oldukları "yankı odası" etkisi yer almaktadır. Sosyal medyada propaganda amacıyla oluşturulan sahte hesaplar tarafından yayılan sahte haberlerin ise sosyal botlar, trol hesaplar ve yarı robot hesaplar aracılığıyla yayıldığı vurgulanmıştır. Trol veya bot hesaplar tarafından benzer zaman dilimlerinde sıkça paylaşılan haberler, gerçek kullanıcılar tarafından da doğru gibi algılanarak kısa sürede birçok gerçek hesap tarafından paylaşılmaktadır. Bu durum, gerçek hesaplar aracılığıyla paylaşılan sahte haberlerin inandırıcılığını artırmaktadır[15].

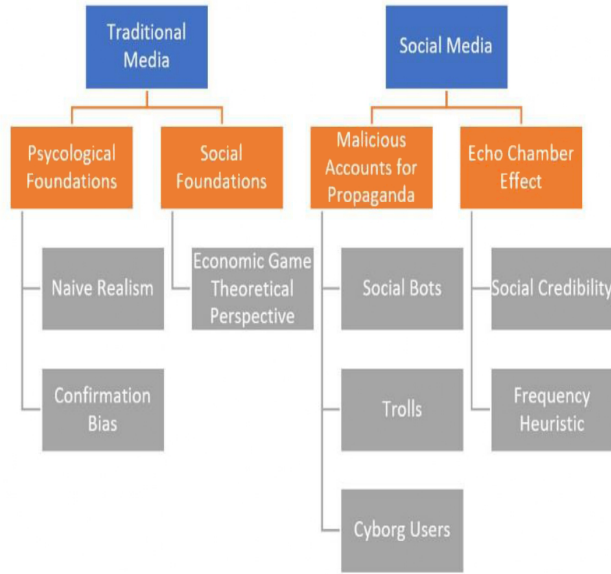


Fig. 4: Sahte haber türleri [4]

### 2.1 Bir Örüntüyü İlginç Kılan Özellikler

Çalışmamızda, Twitter ağında paylaşılan türkçe metinler üzerinde, gönderilen tweetlerdeki haberlerin doğruluk tespitini yapan otomatik bir sistem üzerine çalışılmıştır.

### 2.2 İnsanlar Tarafından Kolayca Anlaşılır Olma

Bu çalışma, sahte haberlerin tespiti üzerine eğilerek bu süreçte kullanılan stratejilere ve çözümlere odaklanmaktadır. Anlaşılır olma faktörü, makaledeki bilgilerin geniş bir kitle tarafından anlaşılabilir olmasını sağlamak amacıyla kritik bir rol üstleniyor. Bu çalışmada, karmaşık terimlerden kaçınmak, örneklerle desteklemek ve görsel araçlar kullanmak gibi yöntemlere odaklanarak, sahte haber tespiti konusunu herkesin anlayabileceği bir tarzda ele alınır. Sahte haberlere karşı mücadelede anlaşılır bir iletişim, toplumun bilinçlenmesi ve etkin önlemlerin alınması açısından hayati bir rol oynar.

### 2.3 Örüntünün Geçerliliği

Bu çalışmada, Twitter üzerinde sahte haberlerin tespiti üzerine odaklanıyor. Sosyal medya platformlarında hızla yayılan yanıltıcı bilgilerle mücadele etmek amacıyla Twitter analizi ve sahte haberlerin tespitine yönelik yeni stratejileri ele alıyoruz. Çalışmada, validasyon süreçlerinin güçlendirilmesi, doğruluk payı yüksek sonuçlar elde etmek için test verilerinin etkili bir şekilde kullanılması gibi konular ele alınarak, sahte haberlerle mücadelede daha güvenilir bir yaklaşım sunuluyor. Bu stratejiler, toplumun doğru bilgilere erişimini artırmak ve sosyal medya üzerinden yayılan yanıltıcı içerikleri azaltmak adına önemli bir adım niteliği taşımaktadır.

### 2.44 Örüntünün Potansiyel Olarak Yararlı Olması

Bu çalışmada, sosyal medyanın önemli bir platformu olan Twitter üzerinde sahte haberlerin tespiti amacıyla potansiyel olarak yararlı verilerin nasıl kullanılabileceğini ele alıyoruz. Sahte haberlerin tespiti, toplumun doğru bilgilere erişimini güvence altına almak ve yanıltıcı içeriklerle mücadele etmek adına kritik bir öneme sahiptir. Bu çalışmada, Twitter verilerinin analiziyle elde

edilen potansiyel yararlı özellikler ve bu verilerin sahte haber tespitinde nasıl etkili bir şekilde kullanılabileceği detaylı bir şekilde inceleniyor. Sahte haber tespiti süreçlerine katkı sağlamak amacıyla Bu çalışma da potansiyel olarak yararlı verilerin sahte haber analizindeki rolünü vurgu yapılmaktadır.

### 2.5 Örüntünün Yenilikçiliği

Bu çalışmada, sahte haberlerin tespiti konusunda yeni bir perspektif sunularak Twitter verileri üzerinde geliştirilen bir model ele alınmaktadır. Sahte haberlerin hızla yayıldığı sosyal medya platformlarında, geleneksel yöntemlerin ötesinde bir yaklaşım benimsenmesi kaçınılmazdır. Bu çalışma da, yeni ve yenilikçi bir modelin nasıl oluşturulduğunu ve bu modelin sahte haberleri etkili bir şekilde tespit etmedeki başarısını detaylı bir şekilde açıklamaktadır. Twitter verilerinin kullanımıyla geliştirilen bu novel(yenilikçi) model, sahte haber analizinde bir adım öne çıkmayı başarıyor. Ayrıca, modelin sağladığı özellikleri somut bir şekilde kanıtlamak için gerçek ve sahte test verileri üzerinde yapılan deneyimler makalenin içerisinde detaylı bir şekilde sunuluyor.

### Diğer Adımlardaki Çalışmalara Dair

Bölüm II'de gibi yani Literatür çalışması kısmında sahte haberlerin tespiti ile ilgili çalışmalar ve çözümler gözlemlenmiştir.

Bölüm III'de yani Metot kısmında kullanılan sınıflandırma algoritmaları tanımlanmış ve formülleri verilmiştir.

Bölüm IV'de bir önceki bölümde kullanılan sınıflandırma algoritmalarının sonuçlarına ulaşılmış ve karşılaştırma yapıp incelenmiştir.

## II. LİTERATÜR İNCELEMESİ

Literatür çalışmalarına bakıldığında, sosyal medya aracılığıyla sahte haberlerin tespiti için yapılan araştırmalara rastlanmaktadır. Örneğin, Mehmet Kayakuş ve Fatma Yiğit Acıkgöz'ün (2023) çalışmalarında birinci adım olarak sahte haberlerle ilgili araştırmalar ve bilgilere ulaşılmaya çalışılmış, bu bilgiler ışığında ise bir taslak oluşturulup çalışmaya başlanmıştır. Ardından, yarı denetimli yapay zeka algoritması yapılandırılmış sahte haber veri setine uygulanmıştır. Veriler yüzde 70 - yüzde 30 oranında rastgele atama yöntemine göre eğitim ve test verisi olarak ikiye ayrılmıştır. Çalışma sonuçları, F1 skoruna göre bakıldığında Naive Bayes sınıflandırma algoritmasının Karar Ağaçları sınıflandırma algoritmasına göre daha başarılı olduğu görülmektedir.[16].

Bu çalışmada, sahte haberlerin tespiti konusunda bu alana farklı bir bakış açısı getirilerek Twitter verileri üzerinde geliştirilen yaratıcı bir modeli ele alıyoruz. Sahte haberlerin hızla yayıldığı günümüz sosyal medya platformlarında, geleneksel yöntemlerin dışında bir yaklaşım benimsemek oldukça önemlidir. Bu çalışma, yeni, anlaşılır ve yenilikçi bir modelin nasıl oluşturulduğunu detaylı bir şekilde açıklamakta ve bu modelin sahte haberleri etkili bir şekilde tespit etme başarısını vurgulamaktadır. Twitter verilerinin kullanımıyla geliştirilen bu yeni model, sahte haber analizi konusunda öne çıkmayı başarmaktadır. Ayrıca, modelin sağladığı özellikleri somut bir şekilde kanıtlamak için gerçek ve test verileri üzerinde yapılan deneyimleri makale içinde detaylı bir şekilde sunmaktadır.



Taşkın ve ekibi (2021), ise yaptıkları çalışmada insanları yanıltabilecek sahte haberleri tespit etmek adına makine öğrenimi tabanlı yöntemler kullanmışlardır. Bu amaçla kullanılan veri setine ön işlem uygulanmıştır ve makine öğrenmesi işlemleriyle sahte haberler tespit edilmiştir. Denetimsiz öğrenme algoritmalarından, Kortalamalar, Negatif Olmayan Matris Çarpımı ve Doğrusal Diskriminant Analizi ; denetimli öğrenme algoritmalarından, K En Yakın Komşu , Destek Vektör Makinaları ve Rassal Orman algoritmaları ile tahmin yapılmıştır. Denetimli öğrenme algoritmalarında 0.86 F1-metrik değeriyle başarılı sonuçlar alınmıştır[17].

### III. METOT

#### 3.1. Veri Seti

Bu çalışmada, belirli bir konuda Twitter’da yayılmış gerçek ve sahte haberleri içeren tweetlerin yapay zeka ile tespit edilmesi amaçlanmıştır. Bu araştırma kapsamında, Twitter’da trend olmuş ve sahte haberleri içeren bir konu seçilmiştir.

Veri seti, eğitim ve test kategorileri olarak iki gruba ayrılmıştır. Eğitim verileri, modelin parametrelerini tanımlamak ve öğrenmek için kullanılmıştır.

Şekil 9’da ise bu veri setindeki toplam sahte ve gerçek haberlerin birbirine oranları verilmiştir. Table 1’de ise veri setimizin ilk halinin 5 örneğini görmektedir.




Fig. 5: Sahte Haberlerin Gerçek Haberlere Oranı

	title	text	subject	date
0	Donald Trump Sends...	Donald Trump just...	News	Dec 31, 2017
1	Drunk Bragging...	House Intelligence...	News	Dec 31, 2017
2	Sheriff David...	On Friday, it was...	News	Dec 30, 2017
3	Trump Is So...	On Christmas day...	News	Dec 29, 2017
4	Pope Francis...	Pope Francis...	News	Dec 25, 2017

TABLE I: Veri Tablosu İlk Hali

#### 3.1.2 Twitter’den Veri Alınması ve Konu Seçimi

Bu konuyla ilgili olarak gönderilen tweetler, "fake news detection" adlı Kaggle çalışmasından referans alınmıştır. Belirlenen tweet mesajları üzerinde metin ön işlemleri ve analizler gerçekleştirildikten sonra, gerçek ve sahte haber olmak üzere iki kategori oluşturulmuştur. Bu kategoriler gerçek ve sahte olarak sınıflandırılmıştır. Gerçek kategorisinde dört öznelik (attribute) bulunmaktadır; bunlar "title", "text", "subject" ve "date"dir. Title yaklaşık 21.000 farklı değere sahiptir. Text yaklaşık 21.000 farklı değere sahiptir. Subject başlığının altında yer alan etiketlerin %53’ü politik haberleri, %47’si ise geriye kalan dünyadan haberleri oluşturmaktadır. Date ise 13-01-2016’dan 31-12-2017’ye kadar olan süreyi içermektedir. Toplamda gerçek ve sahte kategorilerinde yaklaşık 42.000 veri bulunmaktadır. Bu verilere KDD adımları uygulanarak veriler daha derli toplu hale getirilir ve üzerinde daha konforlu çalışılabilir duruma getirilir.

#### 3.2. Veri Ön İşleme Adımları

Bu çalışmada KDD (Knowledge Discovery in Databases) adımları uygulanmıştır, KDD veri madenciliği sürecini ifade eder ve birkaç aşamadan oluşur [18]. KDD aşamaları şunlardır;

1 - Veri Temizleme : Veri madenciliği süreci genellikle gerçek dünya verileriyle başlar. Bu verilerde eksik, hatalı veya tutarsız bilgiler olabilir. Veri temizleme aşamasında bu tür sorunlar giderilir ve veri seti hazırlanır.

2 - Veri Entegrasyonu : Farklı kaynaklardan gelen veriler entegre edilmelidir. Veri entegrasyonu, veri setlerini birleştirme, uyarılma ve bir araya getirme işlemlerini içerir.

3 - Veri Seçimi : İlgili veri özelliklerini ve alt kümelerini seçme aşamasıdır. Bu, analiz amacına uygun verilerin seçilmesini içerir.

4 - Veri Dönüşümü : Veri seti, maddeleme ve normalizasyon gibi işlemlerle dönüştürülür. Bu, veri setinin modelleme aşamalarında daha etkili olmasına yardımcı olabilir.

5 - Veri Madenciliği : Veri madenciliği aşamasında, örüntüleri, ilişkileri veya bilgiyi keşfetmek için çeşitli maddeleme teknikleri kullanılır. Karar ağaçları, destek vektör makineleri, kümeleme gibi algoritmalar bu aşamada kullanılabilir.

6 - Örüntü Değerlendirmesi : Görselleştirmenin ve bilgi sunuşu tekniklerinin kullanıcılara anlık bilgi madenciliği yapılması amacıyla kullanıldığı yer

7 - Bilginin Sunumu : Veri madenciliği uygulanan bilginin kullanıcılarına sunulması amacıyla görselleştirme ve bilgi temsil tekniklerinin kullanıldığı yer.

**3.2.1 Veri Temizleme :** Bu çalışmada ki verilerde eksik, hatalı veya tutarsız bilgiler vardır. Veri temizleme aşamasında, bu tür sorunlar gideriliyor ve veri seti hazırlanıyor. Örneğin, msno.bar() fonksiyonu ile eksik değerleri kontrol etmiş ve isnull().sum() ile eksik değerli sayı bulunuyor. Bu aşamada, eksik verilere, anlamsız karakterlere veya diğer veri bütünlüğü sorunlarına odaklanılmış oldu.

**3.2.2 Veri Entegrasyonu :** Farklı kaynaklardan gelen veriler entegre edilmelidir. Veri entegrasyonu, veri setlerini birleştirme, uyarılma ve bir araya getirme işlemlerini içerir. Sahte ve gerçek haberleri içeren iki ayrı veri setini birleştirerek (pd.concat() ile) bu aşama gerçekleştiriliyor.

**3.2.3 Veri Seçimi :** İlgili veri özelliklerini ve alt kümelerini seçme aşamasıdır. Bu, analiz amacına uygun verilerin seçilmesini içerir. Örneğin, "title", "text", "subject", "date" sütunlarını seçilmiştir.

**3.2.4 Veri Dönüşümü :** Veri seti, maddeleme ve normalizasyon gibi işlemlerle dönüştürülür. Bu, veri setinin modelleme aşamalarında daha etkili olmasına yardımcı olacaktır.

**3.2.5 Veri Madenciligi :** Veri madenciligi aşamasında, örüntüleri, ilişkileri veya bilgiyi keşfetmek için çeşitli maddeleme tekniklerinde kullanılıyor. Bu çalışmada ki veri setinde, "class" sütunu ile sahte ve gerçek haberleri ayırt etme amacına yönelik bir model oluşturmak için veri madenciligi yöntemleri uygulanıyor.

**3.2.6 Örüntü Değerlendirmesi :** Kodda yer alan modellerin (Lojistik Regresyon, Karar Ağacı, Gradyan Arttırıcı, Rastgele Orman, K-En Yakın Komşular, Naive Bayes, Destek Vektör Makinesi) çıktılarına bakarak "pattern evaluation" veya model değerlendirme için elde edilen sonuçlar değerlendirilebilir [19]. Model değerlendirme genellikle doğruluk, hassasiyet, geri çağırma ve F1 puanları gibi metrikler kullanılarak yapılıyor.

**3.2.7 Bilginin Sunumu (Knowledge Presentation):** Sunum aşamasına verilen addır. Verimiz sunmaya uygun mu hazır mı bakıyoruz, ardından iyi bir şekilde sunuyoruz.

### 3.3 Metin Ön İşleme

Ön işleme yöntemi, metin madencilğinde ve uygulamasında büyük öneme sahip olan bir aşamadır. Metin ön işleme adımı kalabalık yaratan veriler, fazlalıklar ve işe yaramayan veriler temizlenir böylece çalışmanın başarısının artması beklenir. Ön işleme için kullanılan harfleri küçük karaktere dönüştürme, karakter temizleme, URL temizleme, HTML etiketlerini temizleme, yeni satırları temizleme, sayıları ve rakamları temizleme işlemleridir.[20]. Bunlar, ön işleme adımı metinler üzerinde yapılabilecek birbirinden farklı metin ön işleme adımlarıdır. Kullandığımız veri setindeki veriler büyük ve küçük harfin kullanılmış olduğu bir belgede ortak bir düzene sahip olmalıdır. Bu durum yazım yanlışlarından ve olabilecek hatalardan kaynaklanabilir. Metin ön işlemede, büyük ya da küçük harf dönüştürme işlemi, bir metindeki tüm harfleri değiştirmeyi ve de hepsinin aynı olmasını hedeflemektedir. Noktalama işaretlerinin kullanımı, web programlama kodları, URL'ler, emojiler, genellikle kullanılan ve sık kullanılmayan kelimeler gibi metinlerde ilgili metine anlam kazandırmayan yaygın sözcükler çıkartılmaktadır. Stopwords adı verilen liste kullanılarak metin verilerindeki stop kelimeleri yani, yaygın olarak kullanılan ve genellikle anlam taşımayan kelimeler analiz edilerek çeşitli stop kelime özellikleri çıkarılmalıdır. Ardından veri çerçevesindeki sütunlar analiz edilir. cat cols: Kategorik (string veya kategori tipinde) sütunları içeren listeleri kodumuzda tek tek yazdırılır. num cols: Sayısal sütunları içeren listeleri kod şeklinde yazdırılır. cat but car: Kategori tipinde olup ancak kardinalitesi

(benzersiz değer sayısı) belirli bir eşik değerinden yüksek olan sütunları içeren listeleri kod şeklinde yazdırılır.

### 3.4 Öznitelik Çıkartma Yöntemleri

Veri setinden "title", "subject" ve "date" sütunlarını çıkarıldı, genellikle veri ön işleme adımının parçalarındandır. Bu attributları çıkarmak veya kullanmamak, analiz amaçlarına ve veri setinin özelliklerine bağlıdır. nedenher bir sütunun çıkarılması veya kullanılmadı açıklamaları :

"title" Sütunu Çıkarılması:

Neden:

Başlık genellikle metin verilerini içerir ve çok sayıda farklı kelime ve karakter içerebilir. Bu nedenle, doğrudan kullanılmadan önce işlenmeleri gerekebilir. Başlıklar, özellikle metin madde modellemesi veya doğal dil işleme uygulamalarında kullanılmak üzere ayrı bir analize tabi tutulabilir. Ancak, özgün analizinize odaklanmak için bu sütunu çıkarmak olası bir durumdur.

"subject" Sütunu Çıkarılması:

Neden:

Konu başlıkları genellikle belirli bir konuyu veya kategoriyi ifade eder. Ancak, bu bilgi, özellikle sınıflandırma modelleri kullanılacaksa, zaten hedef değişken olarak kullanılabilecek "class" sütununda bulunabilir. Bu durumda, benzer bilgileri içeren "subject" sütunu gereksiz olabilir. "date" Sütunu Çıkarılması: Neden: Tarih verisi, zaman serisi analizi veya belirli tarih aralıklarında yapılan analizler için önemli olabilir. Ancak, bu tür bir analiz yapılmıyor ve "date" sütununun modeli etkilemiyor, bu sütunu çıkarmak tercih edilebilir. Sütunları çıkarmak, veri setini basitleştirir ve modeli eğitirken gereksiz gürültüyü azaltır [21].

## IV. DENEYSEL SONUÇLAR

Bu çalışmada Twitterda gönderilen tweetlerin, fake news detection adlı kaggle çalışmasından referans alınarak yeniden derlenip yeni kodlarla tekrardan incelenip farklı bir bakış açısına göre sınıflandırma yöntemlerini kullanarak, veri setinin sonuçlarına bakılmıştır. Veri seti üzerinde yapılan veri ön işleme adımları belirlenen tweet mesajlarının üzerinde yapıldıktan sonra gerçek ve sahte haber adı altında iki kategori oluşturulmuştur. Bunlar gerçek ve sahte olarak kategori edilmiştir. Gerçek kategorisinde 4 adet öznitelik (attribute) bulunmaktadır, bunlar; title, text, subject, datedir. Title yaklaşık 21.000 tane eşsiz değere sahiptir. Text yaklaşık 21.000 tane eşsiz değere sahiptir. Subject başlığının altında ki etiketlerin %53' u politik haberler, %47'si ise geriye kalan dünyadan haberleri oluşturmaktadır. Date ise 13-01-2016'dan 31-12-2017'ye kadar olan süreyi içermektedir. Toplamda gerçek ve sahte kategorilerinde yaklaşık 42.000 tane veri bulunmaktadır. Bu verilere KDD adımları uygulanarak veriler daha derli toplu hale getirilir örneğin; Veri setini inceledikten sonra, haber başlıkları ve metin içerikleri üzerinde bazı ön işlemler yapılmıştır. Özel karakterleri, web sitelerini, HTML etiketlerini, vb. temizlenmiştir. Daha sonra, veriyi eğitim ve test setlerine ayrılıp, metin verilerini sayılara dönüştürmek için TF-IDF vektörleştirme kullanılmıştır. Ardından, bu vektörlerle bir Lojistik Regresyon modeli eğitiyoruz. ve üzerinde daha kolay işlem yapılabilir hale getirilir. ve daha sonrasında ise bu çalışmada

7 farklı sınıflandırma algoritması kullanılmıştır. Kullanılan bu sınıflandırma algoritmaları Lojistik Regresyon Sınıflandırma, Rastgele Orman Sınıflandırma, Karar Ağacı Sınıflandırması, Gradient Arttırıcı Sınıflandırma, K En Yakın Komşu Sınıflandırması, Naive Bayes, Destek Vektör Sınıflandırma algoritmaları kullanılmıştır. Yapılan kodlamada her seferinde rastgele test verileri için 5000 sahte, 5000 gerçek haber verisi alınıp yeni test adı altında birleştirilip makine öğrenmesi için eğitim ve test verilerin ayırıp, metinleri vektörlere dönüştürüp, sınıflandırma algoritma kodları yazılıyor. Kesinlik değeri, bir algoritmanın yaptığı tahminler arasında gerçekten doğru olanların oranını ifade eder. Özellikle sahte ve gerçek haber tespiti probleminde, veri setinde bulunan sahte haberlerin ne kadarının doğru bir şekilde tanımlandığını gösterir. Yüksek kesinlik değeri, algoritmanın sahte haberleri doğru bir şekilde sınıflandırmada başarılı olduğunu belirtir. Bu metrik ne kadar yüksekse, algoritmanın doğru etiketleme konusundaki başarısı o kadar yüksektir ve bizim algoritmamızda ise en yüksek kesinlik değerini Rastgele Orman Sınıflandırması vermiştir. Değeri ise 0.76' dır. Aslında yapılan bu çalışmada, sahte haberlerin otomatik olarak tespit edilmesini sağlayan bir sistem kullanılmıştır. Bu sistem, kısa sürede sahte haberleri belirleyebilme yeteneğiyle dikkat çekmektedir. Bu sayede, sahte haberlerin hızlı bir şekilde tespit edilmesi ve yayılmasının önlenmesi mümkün olmaktadır. Her defasında kod çalıştırıldığında, Rastgele Orman Sınıflandırması'nın PCA uygulanmadan önceki doğruluk skoru 0.76 iken, PCA uygulandıktan sonraki doğruluk oranı 0.75 olarak belirlenmiştir. Bu sonuçlar, çalışmada yer alan diğer altı algoritmadan daha yüksek kesinlik değerlerine işaret etmektedir.

#### 4.1 Denetimli Makine Öğrenmesi Algoritmaları

Bu çalışmada, Twitter'daki atılan tweetlerden elde edilen haberlerin sahte veya gerçek olup olmadığını tahmin etmek için 7 tane sınıflandırma algoritması kullanılmıştır [22]. Bunlar; Lojistik Regresyon Sınıflandırması, Karar Ağacı Sınıflandırması, Gradyan Arttırıcı Sınıflandırma, Rastgele Orman Sınıflandırma, K En Yakın Komşu Sınıflandırması, Naive Bayes'dir [23].

**4.2 Lojistik Regresyon Sınıflandırması** Lojistik Regresyon, genellikle iki sınıflı (binary) sınıflandırma problemlerinde tercih edilen bir modeldir. Sınıflandırma algoritmalarının genel amacı, bağımlı değişkenin değerini belirleyerek sınıflandırmaktır. Bu çalışmada Lojistik Regresyon modeli import edilmiş ve inşa edilmiştir. Daha sonra, model eğitim verileriyle eğitilmiş ve sayıları eşitlemiştir. Test verileri üzerinde tahmin yapılır ve bu tahminleri oluşturan kodlar yazılmıştır. Modelin başarısı kesinlikle değerlendirilir ve sınıflandırma raporu sonuç olarak yazdırılır. PCA ile gerçekleştirilen K-Fold Yaklaşımı sonuçları Şekil 6'da, Karmaşıklık Matrisi Şekil 7'de gösterilmiştir. PCA kullanılmadan yapılan K-Fold Yaklaşımı sonuçları ise Şekil 8'de sergilenmiştir. Temel formüldeki sigmoid fonksiyonu ve katsayılar arasındaki ilişki, bağımlı değişkenin olasılığını tahmin etme sürecinde kritik bir rol oynamaktadır.

```
accuracy for each fold: [0.546 0.546 0.5685 0.559 0.542 ]
Mean accuracy: 0.55
precision for each fold: [0.55481214 0.56650982 0.57891335 0.55790357 0.54330321]
Mean precision: 0.56
recall for each fold: [0.546 0.546 0.5685 0.559 0.542 ]
Mean recall: 0.55
f1 for each fold: [0.53220508 0.52901891 0.55495953 0.5499326 0.52934427]
Mean f1: 0.54
sensitivity for each fold: [0.72064777 0.74947589 0.7439759 0.69385797 0.70196078]
Mean sensitivity: 0.72
specificity for each fold: [0.37549407 0.36042065 0.39442231 0.41231733 0.3755102 ]
Mean specificity: 0.38
true_positive_rate for each fold: [0.72064777 0.74947589 0.7439759 0.69385797 0.70196078]
Mean true_positive_rate: 0.72
false_positive_rate for each fold: [0.62450593 0.63957935 0.60557769 0.58768267 0.6244898 ]
Mean false_positive_rate: 0.62
```

Fig. 6: Lojistik Regresyon için PCA ile K-Fold yaklaşımı




Fig. 7: Lojistik Regresyon için Karmaşıklık Matrisi

```
accuracy for each fold: [0.6285 0.6335 0.618 0.6295 0.6325]
Mean accuracy: 0.63
precision for each fold: [0.63923712 0.65118791 0.62725302 0.63080417 0.6363768 ]
Mean precision: 0.64
recall for each fold: [0.6285 0.6335 0.618 0.6295 0.6325]
Mean recall: 0.63
f1 for each fold: [0.62257758 0.62795592 0.61143822 0.62523017 0.62814936]
Mean f1: 0.62
sensitivity for each fold: [0.75708502 0.77044025 0.74899598 0.72840691 0.73627451]
Mean sensitivity: 0.75
specificity for each fold: [0.50296443 0.50860421 0.48804781 0.52192067 0.5244898 ]
Mean specificity: 0.51
true_positive_rate for each fold: [0.75708502 0.77044025 0.74899598 0.72840691 0.73627451]
Mean true_positive_rate: 0.75
false_positive_rate for each fold: [0.49703557 0.49139579 0.51195219 0.47807933 0.4755102 ]
Mean false_positive_rate: 0.49
```

Fig. 8: Lojistik Regresyon için PCA Olmadan K-Fold yaklaşımı

**4.3 Karar Ağacı Sınıflandırması** Karar ağaçları, veri madenciliği ve makine öğrenimi alanında oldukça yaygın olarak kullanılan bir tekniktir. Bu yöntem hem sınıflandırma hem de regresyon problemlerine uygulanabilir ve özellikle anlaşılabilir olması ve insanlar tarafından yorumlanabilir olması nedeniyle tercih edilir. Bu çalışmada, karar ağacı sınıflandırma kullanılarak bir model oluşturulmuş ve test verileri üzerinde tahminler gerçekleştirilmiştir. Algoritma, veri kümesini bölerek ve her alt küme için özel bir sınıflandırma modeli oluşturarak çalışmaktadır. Modelin başarısı kesinlikle değerlendirilir ve sınıflandırma raporu sonuçlarını ortaya koymaktadır. PCA'lı K-Fold Yaklaşımı ile elde edilen sonuçlar Şekil 9'da, Karmaşıklık Matrisi Şekil 10'da görülmektedir. PCA kullanılmadan yapılan K-Fold Yaklaşımı sonuçları ise Şekil 11'de paylaşılmıştır.



```

Decision Tree Accuracy: 0.6945
accuracy for each fold: [0.695    0.67875  0.683125 0.69375 0.676875]
Mean accuracy: 0.69
f1 for each fold: [0.69446433 0.67821909 0.68312017 0.69385916 0.67687386]
Mean f1: 0.69
recall for each fold: [0.695    0.67875  0.683125 0.69375 0.676875]
Mean recall: 0.69
precision for each fold: [0.69630492 0.68000805 0.68311587 0.69428043 0.67687749]
Mean precision: 0.69
sensitivity for each fold: [0.65331665 0.63795256 0.67477593 0.69073406 0.67875 ]
Mean sensitivity: 0.67
specificity for each fold: [0.73657928 0.71964956 0.69108669 0.6970091 0.675 ]
Mean specificity: 0.70
true_positive_rate for each fold: [0.65331665 0.63795256 0.67477593 0.69073406 0.67875 ]
Mean true_positive_rate: 0.67
false_positive_rate for each fold: [0.26342072 0.28035044 0.30891331 0.3029909 0.325 ]
Mean false_positive_rate: 0.30

```

Fig. 9: Karar Ağacı Sınıflandırması için PCA ile K-Fold yaklaşımı

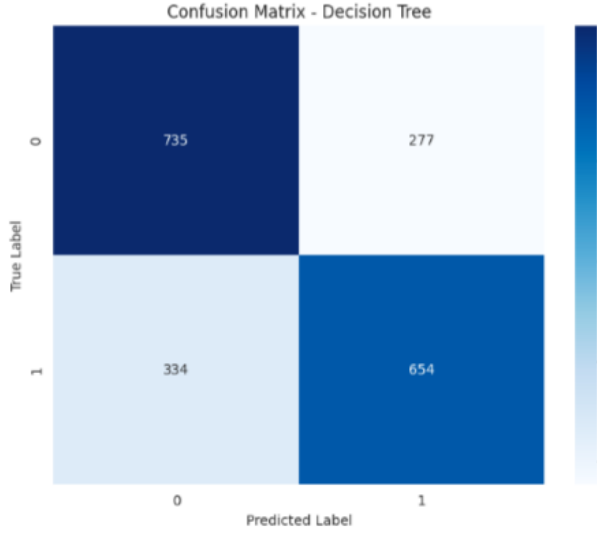


Fig. 10: Karar Ağacı Sınıflandırması için Karmaşıklık Matrisi

```

accuracy for each fold: [0.719 0.7065 0.696 0.696 0.693 ]
Mean accuracy: 0.70
precision for each fold: [0.71900211 0.70627796 0.69610097 0.70026034 0.69480816]
Mean precision: 0.70
recall for each fold: [0.719 0.7065 0.696 0.696 0.693 ]
Mean recall: 0.70
f1 for each fold: [0.71895502 0.70619614 0.6959328 0.695695 0.69273556]
Mean f1: 0.70
sensitivity for each fold: [0.70748988 0.67505241 0.68172691 0.65163148 0.65882353]
Mean sensitivity: 0.67
specificity for each fold: [0.73023715 0.73518164 0.71015936 0.74425887 0.72857143]
Mean specificity: 0.73
true_positive_rate for each fold: [0.70748988 0.67505241 0.68172691 0.65163148 0.65882353]
Mean true_positive_rate: 0.67
false_positive_rate for each fold: [0.26976285 0.26481836 0.28984064 0.25574113 0.27142857]
Mean false_positive_rate: 0.27

```

Fig. 11: Karar Ağacı Sınıflandırması için PCA Olmadan K-Fold yaklaşımı

#### 4.4 Rastgele Orman Sınıflandırma

Rastgele Orman Sınıflandırma Metodu, çok sayıda karar ağacının bir araya getirilerek oluşturulduğu bir ensemble öğrenme tekniğidir. Bu metodoloji, her bir ağacın bağımsız olarak eğitildiği ve genel modelin bu ağaçların tahminlerinin ortalaması veya modu alınarak elde edildiği bir yaklaşımı benimser. Rastgele Orman'ın temel amacı, tek bir karar ağacının aşırı uydurmalar eğilimini azaltarak daha genel ve güvenilir bir model elde etmektir. Modelin kesin başarısı değerlendirilir ve sınıflandırma raporu sonuç olarak gösterilir. PCA kullanılarak gerçekleştirilen K-Fold Yaklaşımı ile elde edilen bulgular Şekil 12'de, Karmaşıklık Matrisi Şekil 13'te sergilenmiştir. PCA olmadan yapılan K-Fold Yaklaşımı sonuçları da Şekil 14'te mevcuttur.

```

Random Forest Accuracy: 0.75
accuracy for each fold: [0.758125 0.72    0.750625 0.745625 0.754375]
Mean accuracy: 0.75
f1 for each fold: [0.75778449 0.71999475 0.75035454 0.74511358 0.75394354]
Mean f1: 0.75
recall for each fold: [0.758125 0.72    0.750625 0.745625 0.754375]
Mean recall: 0.75
precision for each fold: [0.75965743 0.72000975 0.75339659 0.74589627 0.75617181]
Mean precision: 0.75
sensitivity for each fold: [0.79599499 0.72409488 0.79257362 0.7833935 0.79625 ]
Mean sensitivity: 0.78
specificity for each fold: [0.72034956 0.71589487 0.71062271 0.70481144 0.7125 ]
Mean specificity: 0.71
true_positive_rate for each fold: [0.79599499 0.72409488 0.79257362 0.7833935 0.79625 ]
Mean true_positive_rate: 0.78
false_positive_rate for each fold: [0.27965044 0.28410513 0.28937729 0.29518856 0.2875 ]
Mean false_positive_rate: 0.29

```

Fig. 12: Rastgele Orman Sınıflandırma için PCA ile K-Fold yaklaşımı

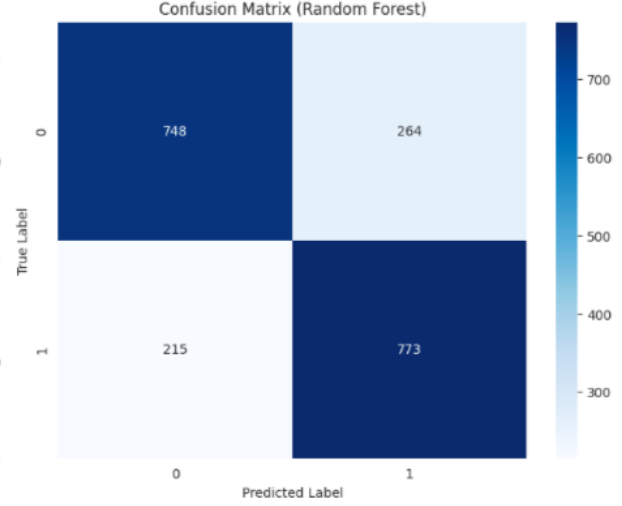


Fig. 13: Rastgele Orman Sınıflandırma için Karmaşıklık Matrisi

```

accuracy for each fold: [0.7595 0.758 0.762 0.768 0.746 ]
Mean accuracy: 0.76
precision for each fold: [0.75991912 0.75873519 0.76226454 0.76881856 0.74614426]
Mean precision: 0.76
recall for each fold: [0.7595 0.758 0.762 0.768 0.746 ]
Mean recall: 0.76
f1 for each fold: [0.75947685 0.75812206 0.76196073 0.76810213 0.74602439]
Mean f1: 0.76
sensitivity for each fold: [0.7742915 0.76519916 0.77610442 0.75815739 0.74313725]
Mean sensitivity: 0.76
specificity for each fold: [0.74505929 0.75143403 0.74800797 0.77870564 0.74897959]
Mean specificity: 0.75
true_positive_rate for each fold: [0.7742915 0.76519916 0.77610442 0.75815739 0.74313725]
Mean true_positive_rate: 0.76
false_positive_rate for each fold: [0.25494071 0.24856597 0.25199203 0.22129436 0.25102041]
Mean false_positive_rate: 0.25

```

Fig. 14: Rastgele Orman Sınıflandırma için PCA Olmadan K-Fold yaklaşımı

#### 4.5 Gradyan Arttırıcı Sınıflandırma

Gradient Boosting, bir ensemble öğrenme tekniği olarak tanınır ve özellikle zayıf karar ağaçlarını bir araya getirerek güçlü bir model oluşturmayı amaçlar. Bu metot, hata azaltma stratejisi kullanarak, sırayla eklenen zayıf karar ağaçlarıyla modelin başarısını artırır. Gradient Boosting'in sıkça kullanılan bir uygulaması, özellikle sınıflandırma ve regresyon problemleri için tercih edilen Gradient Boosted Trees (GBT) adı verilen karar ağaçlarıdır. Modelin doğruluğu değerlendirilir ve sınıflandırma raporu olarak sunulur. PCA'lı K-Fold Yaklaşımı ile elde edilen sonuçlar Şekil 15'te, Karmaşıklık Matrisi Şekil 16'da sergilenmiştir. Ayrıca, PCA kullanılmadan gerçekleştirilen K-Fold Yaklaşımı sonuçları da Şekil 17'de bulunmaktadır.

Gradient Boosting Accuracy: 0.7115  
accuracy for each fold: [0.73 0.7075 0.72125 0.726875 0.73875 ]  
Mean accuracy: 0.72  
f1 for each fold: [0.7277019 0.70507767 0.7173558 0.72270955 0.73524866]  
Mean f1: 0.72  
recall for each fold: [0.73 0.7075 0.72125 0.726875 0.73875 ]  
Mean recall: 0.72  
precision for each fold: [0.73821144 0.71438332 0.73891366 0.73505307 0.75208531]  
Mean precision: 0.74  
sensitivity for each fold: [0.82227785 0.79775281 0.84763124 0.83754513 0.85375 ]  
Mean sensitivity: 0.83  
specificity for each fold: [0.63795256 0.61702128 0.6007326 0.60728218 0.62375 ]  
Mean specificity: 0.62  
true\_positive\_rate for each fold: [0.82227785 0.79775281 0.84763124 0.83754513 0.85375 ]  
Mean true\_positive\_rate: 0.83  
false\_positive\_rate for each fold: [0.36204744 0.38297872 0.3992674 0.39271782 0.37625 ]  
Mean false\_positive\_rate: 0.38

Fig. 15: Gradyan Arttırıcı Sınıflandırma için PCA ile K-Fold yaklaşımı

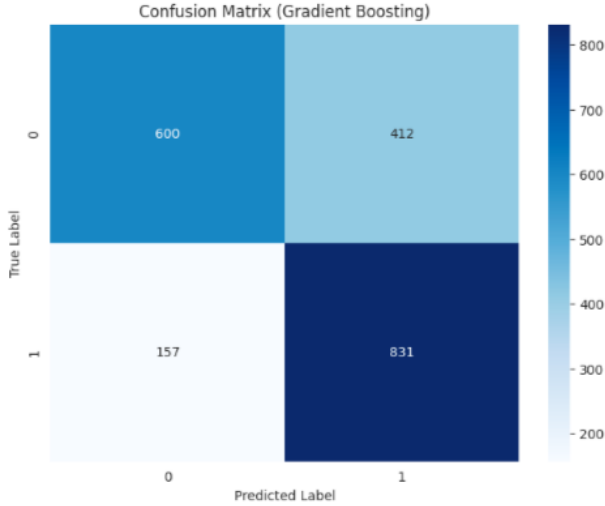


Fig. 16: Gradyan Arttırıcı Sınıflandırma için Karmaşıklık Matrisi

Gradient Boosting Accuracy: 0.7105  
accuracy for each fold: [0.719375 0.695625 0.719375 0.7375 0.730625]  
Mean accuracy: 0.72  
f1 for each fold: [0.71654087 0.69327651 0.71574588 0.73328281 0.72664762]  
Mean f1: 0.72  
recall for each fold: [0.719375 0.695625 0.719375 0.7375 0.730625]  
Mean recall: 0.72  
precision for each fold: [0.72870378 0.70164912 0.73574519 0.74689652 0.74487724]  
Mean precision: 0.73  
sensitivity for each fold: [0.81977472 0.78277154 0.84122919 0.85078219 0.85125 ]  
Mean sensitivity: 0.83  
specificity for each fold: [0.61922597 0.60826033 0.6031746 0.61508453 0.61 ]  
Mean specificity: 0.61  
true\_positive\_rate for each fold: [0.81977472 0.78277154 0.84122919 0.85078219 0.85125 ]  
Mean true\_positive\_rate: 0.83  
false\_positive\_rate for each fold: [0.38077403 0.39173967 0.3968254 0.38491547 0.39 ]  
Mean false\_positive\_rate: 0.39

Fig. 17: Gradyan Arttırıcı Sınıflandırma için PCA Olmadan K-Fold yaklaşımı

#### 4.6 K En Yakın Komşu Algoritması

K-En Yakın Komşular (KNN), sınıflandırma ve regresyon problemleri için kullanılan bir makine öğrenme algoritmasıdır. KNN, basit ve etkili bir algoritma olup özellikle küçük boyutlu veri setlerinde iyi performans gösterir. Kesinlik ile modelin başarısı değerlendirilir ve sınıflandırma raporu sonuç olarak yazdırılır. PCA li K-Fold Yaklaşımı ile elde edilen sonuçlar Şekil 18. , Karmaşıklık Matrisi Şekil 19. gösterilmiştir. PCA olmadan K-Fold Yaklaşımı ile elde edilen sonuçlar da Şekil 20. gösterilmiştir.

KNN Accuracy: 0.6745  
accuracy for each fold: [0.680625 0.65375 0.675 0.65625 0.681875]  
Mean accuracy: 0.67  
f1 for each fold: [0.67982474 0.6529463 0.67421171 0.65535784 0.68128226]  
Mean f1: 0.67  
recall for each fold: [0.680625 0.65375 0.675 0.65625 0.681875]  
Mean recall: 0.67  
precision for each fold: [0.68253622 0.65510907 0.67873753 0.65608121 0.68323812]  
Mean precision: 0.67  
sensitivity for each fold: [0.73091364 0.70162297 0.73111396 0.70276775 0.725 ]  
Mean sensitivity: 0.72  
specificity for each fold: [0.63046192 0.6057572 0.62148962 0.60598179 0.63875 ]  
Mean specificity: 0.62  
true\_positive\_rate for each fold: [0.73091364 0.70162297 0.73111396 0.70276775 0.725 ]  
Mean true\_positive\_rate: 0.72  
false\_positive\_rate for each fold: [0.36953808 0.3942428 0.37851038 0.39401821 0.36125 ]  
Mean false\_positive\_rate: 0.38

Fig. 18: K-En Yakın Komşu Algoritması için PCA ile K-Fold yaklaşımı

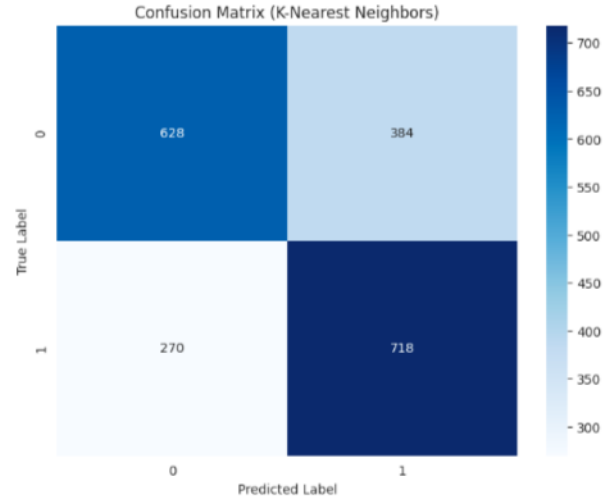


Fig. 19: K-En Yakın Komşu Algoritması için Karmaşıklık Matrisi

KNN Accuracy: 0.673  
accuracy for each fold: [0.68125 0.654375 0.67625 0.65625 0.68125 ]  
Mean accuracy: 0.67  
f1 for each fold: [0.68043116 0.65355173 0.67550534 0.65531014 0.68067322]  
Mean f1: 0.67  
recall for each fold: [0.68125 0.654375 0.67625 0.65625 0.68125 ]  
Mean recall: 0.67  
precision for each fold: [0.68321524 0.65577688 0.67987208 0.65610376 0.68256906]  
Mean precision: 0.67  
sensitivity for each fold: [0.73216521 0.70287141 0.73111396 0.70397112 0.72375 ]  
Mean sensitivity: 0.72  
specificity for each fold: [0.63046192 0.6057572 0.62393162 0.6046814 0.63875 ]  
Mean specificity: 0.62  
true\_positive\_rate for each fold: [0.73216521 0.70287141 0.73111396 0.70397112 0.72375 ]  
Mean true\_positive\_rate: 0.72  
false\_positive\_rate for each fold: [0.36953808 0.3942428 0.37606838 0.3953186 0.36125 ]  
Mean false\_positive\_rate: 0.38

Fig. 20: K-En Yakın Komşu Algoritması için PCA Olmadan K-Fold yaklaşımı

#### 4.7 Naive Bayes Sınıflandırması

Bayes Teoremi: Naive Bayes sınıflandırıcı, Bayes Teoremi'ni temel alır. Bayes Teoremi, bir olayın gerçekleşme olasılığını diğer bağlamdaki bilgilerle güncelleyen bir teoremdir. Naive (Basit) Bayes Önermesi: "Naive" ifadesi, modelin her özelliği arasındaki bağımsızlığı varsayar. Yani, bir özelliğin varlığı veya yokluğu, diğer özelliklerin varlığını veya yokluğunu etkilemez. Metin Verileri ve Özellik Çıkarma: Metin verileri üzerinde çalışırken, öncelikle metin verilerini özelliklere dönüştürmek gerekir. Bu genellikle "TF-IDF" (Terim Frekansı-Tersine Döküman Frekansı ) gibi yöntemlerle yapılır. Sınıflandırma: Naive Bayes sınıflandırıcısı, özellik vektörlerini ve sınıf etiketlerini kullanarak bir model oluşturur. Metin belgeleri üzerindeki özellik vektörleri,

kelime frekansları veya TF-IDF değerleri olabilir. Bir belge yeni geldiğinde, Naive Bayes modeli, bu belgenin her sınıfa ait olma olasılığını hesaplar. Ardından, belgeyi en yüksek olasılığa sahip sınıfa sınıflandırır. Kesinlik ile modelin başarısı değerlendirilir ve sınıflandırma raporu sonuç olarak yazdırılır. PCA li K-Fold Yaklaşımı ile elde edilen sonuçlar Şekil 21. , Karmaşıklık Matrisi Şekil 22. gösterilmiştir. PCA olmadan K-Fold Yaklaşımı ile elde edilen sonuçlar da Şekil 23. gösterilmiştir.

```
Naive Bayes Accuracy: 0.562
accuracy for each fold: [0.585625 0.57375 0.56375 0.58375 0.5875 ]
Mean accuracy: 0.58
f1 for each fold: [0.53586403 0.52360382 0.51207161 0.5270376 0.54285714]
Mean f1: 0.53
recall for each fold: [0.585625 0.57375 0.56375 0.58375 0.5875 ]
Mean recall: 0.58
precision for each fold: [0.65080391 0.62654557 0.62711097 0.63112247 0.64358974]
Mean precision: 0.64
sensitivity for each fold: [0.91364205 0.89762797 0.90012804 0.91215403 0.9 ]
Mean sensitivity: 0.90
specificity for each fold: [0.25842697 0.24906133 0.24297924 0.22886866 0.275 ]
Mean specificity: 0.25
true_positive_rate for each fold: [0.91364205 0.89762797 0.90012804 0.91215403 0.9 ]
Mean true_positive_rate: 0.90
false_positive_rate for each fold: [0.74157303 0.75093867 0.75702076 0.77113134 0.725 ]
Mean false_positive_rate: 0.75
```

Fig. 21: Naive Bayes Sınıflandırması için PCA ile K-Fold yaklaşımı




Fig. 22: Naive Bayes Sınıflandırması için Karmaşıklık Matrisi

```
Naive Bayes Accuracy: 0.566
accuracy for each fold: [0.57375 0.578125 0.56 0.603125 0.585625]
Mean accuracy: 0.58
f1 for each fold: [0.4987655 0.50797546 0.4851621 0.53511811 0.51649403]
Mean f1: 0.51
recall for each fold: [0.57375 0.578125 0.56 0.603125 0.585625]
Mean recall: 0.58
precision for each fold: [0.68515744 0.6804295 0.67069466 0.70386778 0.70001825]
Mean precision: 0.69
sensitivity for each fold: [0.9612015 0.95505618 0.95390525 0.96510229 0.96375 ]
Mean sensitivity: 0.96
specificity for each fold: [0.18726592 0.20025031 0.18437118 0.21196359 0.2075 ]
Mean specificity: 0.20
true_positive_rate for each fold: [0.9612015 0.95505618 0.95390525 0.96510229 0.96375 ]
Mean true_positive_rate: 0.96
false_positive_rate for each fold: [0.81273408 0.79974969 0.81562882 0.78803641 0.7925 ]
Mean false_positive_rate: 0.80
```

Fig. 23: Naive Bayes Sınıflandırması için PCA Olmadan K-Fold yaklaşımı

#### 4.8 Destek Vektör Kullanarak İkili Sınıflandırma

Destek Vektör Makinası (Support Vector Machines - SVM), özellikle sınıflandırma ve regresyon problemleri için kullanılan bir makine öğrenmesi algoritmasıdır. Temelde, belirli bir veri kümesindeki sınıfları birbirinden ayırmak için bir hiperdüzlem (hyperplane) oluşturmaya

çalışır. SVM'nin ikili sınıflandırma görevindeki amacı, veri kümesindeki iki sınıfı en iyi şekilde birbirinden ayıran bir hiperdüzlem bulmaktır. Hiperdüzlem, özellik uzayında bir alt uzayı iki sınıfa bölen bir düzlemdir. SVM'nin belirli bir sınıfa ait veri noktalarını sınıflandırmadaki başarısı, bu noktaların hiperdüzleme olan uzaklıklarına dayanır. Kesinlik ile modelin başarısı değerlendirilir ve sınıflandırma raporu sonuç olarak yazdırılır. PCA li K-Fold Yaklaşımı ile elde edilen sonuçlar Şekil 24. , Karmaşıklık Matrisi Şekil 25. gösterilmiştir. PCA olmadan K-Fold Yaklaşımı ile elde edilen sonuçlar da Şekil 26. gösterilmiştir.

```
accuracy for each fold: [0.5245 0.5245 0.5265 0.552 0.5425]
Mean accuracy: 0.53
precision for each fold: [0.51186658 0.50096463 0.51596091 0.55155367 0.53554502]
Mean precision: 0.52
recall for each fold: [0.80769231 0.81656184 0.79518072 0.74952015 0.7754902 ]
Mean recall: 0.79
f1 for each fold: [0.62661955 0.62096453 0.62583959 0.635476 0.63356027]
Mean f1: 0.63
sensitivity for each fold: [0.80769231 0.81656184 0.79518072 0.74952015 0.7754902 ]
Mean sensitivity: 0.79
specificity for each fold: [0.24802372 0.2581262 0.25996016 0.33716075 0.3 ]
Mean specificity: 0.28
true_positive_rate for each fold: [0.80769231 0.81656184 0.79518072 0.74952015 0.7754902 ]
Mean true_positive_rate: 0.79
false_positive_rate for each fold: [0.75197628 0.7418738 0.74003984 0.66283925 0.7 ]
Mean false_positive_rate: 0.72
```

Fig. 24: Destek Vektör Makinesi Kullanarak İkili Sınıflandırma için PCA ile K-Fold yaklaşımı




Fig. 25: Destek Vektör Makinesi Kullanarak İkili Sınıflandırma için Karmaşıklık Matrisi

```
SVM Accuracy: 0.5245
accuracy for each fold: [0.53875 0.541875 0.50875 0.565625 0.529375]
Mean accuracy: 0.54
f1 for each fold: [0.50009413 0.50655423 0.47780973 0.53089483 0.49612706]
Mean f1: 0.50
recall for each fold: [0.53875 0.541875 0.50875 0.565625 0.529375]
Mean recall: 0.54
precision for each fold: [0.55665534 0.55816035 0.5196256 0.57720811 0.53990838]
Mean precision: 0.55
sensitivity for each fold: [0.81727159 0.80898876 0.75928297 0.82430806 0.78625 ]
Mean sensitivity: 0.80
specificity for each fold: [0.26092385 0.27409262 0.26984127 0.28608583 0.2725 ]
Mean specificity: 0.27
true_positive_rate for each fold: [0.81727159 0.80898876 0.75928297 0.82430806 0.78625 ]
Mean true_positive_rate: 0.80
false_positive_rate for each fold: [0.73907615 0.72590738 0.73015873 0.71391417 0.7275 ]
Mean false_positive_rate: 0.73
```

Fig. 26: Destek Vektör Makinesi Kullanarak İkili Sınıflandırma için PCA Olmadan K-Fold yaklaşımı

**PCA Olmadan Sınıflandırma Yöntemleri**

Sınıflandırma Algoritmaları	Acc.	Prec.	Rec.	F1.	Sens.	Spec.	TP.	FP.
Lojistik Regresyon	0.63	0.64	0.63	0.62	0.75	0.51	0.75	0.49
Karar Ağaçları	0.70	0.70	0.70	0.70	0.66	0.73	0.66	0.27
Rastgele Orman	0.76	0.76	0.76	0.76	0.76	0.75	0.76	0.25
Gradyan Arttırma	0.72	0.73	0.72	0.72	0.83	0.61	0.83	0.39
K-En Yakın Komşu	0.67	0.91	0.67	0.67	0.72	0.62	0.72	0.38
Naive Bayes	0.58	0.69	0.58	0.51	0.96	0.20	0.96	0.80
Destek Vektör	0.52	0.55	0.54	0.50	0.80	0.27	0.80	0.73

**PCA İle Sınıflandırma Yöntemleri**

Sınıflandırma Algoritmaları-PCA	Acc.	Prec.	Rec.	F1.	Sens.	Spec.	TP.	FP.
Lojistik Regresyon	0.55	0.56	0.55	0.54	0.72	0.38	0.72	0.62
Karar Ağaçları	0.70	0.69	0.69	0.69	0.67	0.70	0.67	0.30
Rastgele Orman	0.75	0.75	0.75	0.75	0.78	0.71	0.78	0.29
Gradyan Arttırma	0.71	0.72	0.72	0.74	0.83	0.62	0.83	0.38
K-En Yakın Komşu	0.67	0.67	0.67	0.67	0.72	0.62	0.72	0.38
Naive Bayes	0.58	0.64	0.58	0.53	0.90	0.25	0.90	0.75
Destek Vektör	0.53	0.52	0.79	0.63	0.63	0.28	0.79	0.72

**V. TARTIŞMALAR**

Yapılan araştırmalara göre Türkiye ve dünya genelindeki insanların sahte haberlere maruz kalma oranı oldukça yüksektir. Bunun yanı sıra, sahte haberleri ayırt etme becerisinin düşük olduğu gözlemlenmiştir. Ayrıca, sahte haberlerin özellikle paylaşıldıktan sonraki ilk 2 saat içinde hızla yayıldığı düşünüldüğünde, sahte haberleri tespit etmek için otomatik tespit sistemlerinin kullanılması büyük bir önem arz etmektedir. Denetimli öğrenme algoritmaları, etiketlenmiş veri setlerine dayanarak kümeleme yapmaktadır. Bu çalışmada, her konuda kategorize edilmiş 2 küme (gerçek, sahte) bulma görevi denetimli öğrenme algoritmalarına verilmiştir. Her konuda bulunan veriler, eğitim ve test seti olarak %50'şer oranda ayrılmıştır. Gerçek ve sahte haber kümeleri, eğitim seti kullanılarak 7 farklı denetimli öğrenme algoritması ile belirlenmiştir. Elde edilen kümeler, kümeleme saflığı yöntemiyle gerçek veya sahte haber oldukları tespit edilmiştir. PCA İle Sınıflandırma Yöntemleri tablosunda görüldüğü üzere Rastgele Orman; Lojistik Regresyon Sınıflandırma, Karar

Ağacı Sınıflandırması, Gradyant Arttırıcı Sınıflandırma, K-En Yakın Komşu Sınıflandırması, Naive Bayes, Destek Vektör Sınıflandırma algoritmalarına göre daha yüksek Kesinlik değerine ulaşmıştır. Bu değer 0.75'tir.

PCA İle Sınıflandırma Yöntemleri tablosunda görüldüğü üzere en düşük Destek Vektör Sınıflandırma algoritması; Rastgele Orman, Lojistik Regresyon Sınıflandırma, Karar Ağacı Sınıflandırması, Gradyant Arttırıcı Sınıflandırma, K-En Yakın Komşu Sınıflandırması, Naive Bayes gibi sınıflandırma algoritmalarına göre en düşük Kesinlik değerine ulaşmıştır. Bu değer 0.53'tür. PCA Olmadan Sınıflandırma

Yöntemleri tablosunda görüldüğü üzere, Destek Vektör Sınıflandırma algoritması; Naive Bayes, Rastgele Orman Sınıflandırması, Karar Ağacı Sınıflandırması, Gradient Arttırıcı Sınıflandırma, K-En Yakın Komşu Sınıflandırması, Lineer Regresyon Sınıflandırma algoritmalarına göre daha düşük Kesinlik değerinesahiptir. ve bu değer 0.52'dir.

PCA Olmadan Sınıflandırma Yöntemleri tablosunda görüldüğü üzere, Rastgele Orman Sınıflandırması, Destek Vektör Sınıflandırma algoritması, Naive Bayes, Karar Ağacı Sınıflandırması, Gradient Arttırıcı Sınıflandırma, K-En Yakın Komşu Sınıflandırması, Lineer Regrasyon Sınıflandırma algoritmalarına göre en yüksek Kesinlik değerine sahiptir. ve bu değer 0.76'dır.

Diğer kaynaklara baktığımızda, denetimsiz sınıflandırma algoritmalarını kullanarak elde ettikleri sonuçları değerlendirdiklerini görüyoruz. Bu çalışmadaki eğitim ve test veri setlerinin ayrımı ile kullanılan farklı denetimli sınıflandırma algoritmalarının, referans alınan makaleye kıyasla daha üstün performans gösterdiğini gözlemliyoruz. Özetle, bu çalışmada etiketli veri kullanılmasının, aynı etiketlere sahip veriler arasındaki benzerlikleri daha etkili bir şekilde çözme yeteneği açısından denetimli öğrenme algoritmalarını avantajlı kıldığı görülmektedir. F1 metrik değerlerini optimize etmek için, sosyal medya platformlarında kullanıcıların takip ettiği kişiler ve bu kişilerin takip ettiği hesapların detaylı bir şekilde incelenmesi gerekebilir. Bu inceleme sırasında, hesapların bot, sahte veya propaganda amaçlı açılmış hesaplar olup olmadığına dair farklılıklar göz önüne alınabilir. Bu nedenle, gelecekteki çalışmalarda arkadaşlık grafiği kullanılarak otomatik tespit sistemine bu grafik girdi olarak verilecek ve algoritmanın başarısının daha da artırılması hedeflenecektir.[17].



## REFERENCES

- [1] Tuğrulcan Elmas. T24, 2023.
- [2] Selman Akyüz. *SAHTE HABER*. 02 2019.
- [3] Tuğçe Esin PINARBAŞI and Fatma Kübra ASTAM. HaberİN dÖnÜ(ŞÜ)mÜ: Sosyal medya gazetecİLİĞİ pratiklerİ. *İnönü Üniversitesi İletişim Fakültesi Elektronik Dergisi (İNİF E-Dergi)*, 5(1):70–87, 2020.
- [4] Kezban Karagöz. Post truth Çağında yayıncılığın geleceği, 2018.
- [5] Mehmet Atakan Foça. Duvar gazetesi, 2018.
- [6] Ersel KİRAZ. Sosyal medyada sahte haberİN yayılmasında kullanıcı faktÖrÜ. *İnönü Üniversitesi İletişim Fakültesi Elektronik Dergisi (İNİF E-Dergi)*, 5(1):9–24, 2020.
- [7] Barış Yetkin. DİjİtalleŞen sİyasal İletİŞİmde bİLİŞİmsel propaganda: Botlar. pages 51–72, 05 2019.
- [8] Deniz ERGÜREL. Teknolojİ ve İnternetle yenİden Şekİllenen medya. *İletişim ve Diplomasi*, (1):167–177, 2013.
- [9] Aygün ÖZSALİH. Yapay zekâ yoluyla oluŞturulan sahte haberlerİN medya gÜndemİNİ bellİrlemesİ. *Turkish Online Journal of Design Art and Communication*, 13(3):533–550, 2023.
- [10] Hikmet Tosyali. Dİjİtal Çağda siyasal İletİşim: Algorİtmalar ve botlar. 04 2021.
- [11] Kai Shu, Amy Sliva, Suhang Wang, Jiliang Tang, and Huan Liu. Fake news detection on social media: A data mining perspective. *ACM SIGKDD Explorations Newsletter*, 19, 08 2017.
- [12] TırŞe ERBAYSAL FİLİBELİ and Orhan ŞENER. Manipule edilmiş enformasyonel bir vitrin ve populist bir enformasyon alanı olarak twitter. *Moment Dergi*, 6(2):492–515, 2019.
- [13] Mesut Toğaçar, Kamil Eşİdir, and Burhan Ergen. Yapay zekâ tabanlı doğal dil İŞleme yaklaşımları kullanarak İnternet ortamında yayınlanmış sahte haberlerin tespiti. *Journal of Intelligent Systems: Theory and Applications*, 5:1–8, 10 2021.
- [14] Feyza ALTUNBEY ÖZBAY and Bilal ALATAŞ. Çevrimiçi sosyal medyada sahte haber tespiti. *Dicle Üniversitesi Mühendislik Fakültesi Mühendislik Dergisi*, 11(1):91–103, 2020.
- [15] Süleyman Gökhan Taşkın, Ecir Uğur Küçükşİlle, and Kamil Topal. Twitter üzerinde türkçe sahte haber tespiti, 2021.
- [16] Mehmet KAYAKUŞ and Fatma YİĞİT AÇIKGÖZ. Twitter’da makine Öğrenmesi yöntemleriyle sahte haber tespiti. *Abant Sosyal Bilimler Dergisi*, 23(2):1017–1027, 2023.
- [17] Süleyman Gökhan TAŞKIN, Ecir Uğur KÜÇÜKSİLLE, and Kamil TOPAL. Twitter üzerinde türkçe sahte haber tespiti. *Balıkesir Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, 23:151–172, 2021.
- [18] Murat Emeç and Mehmet Ozcanhan. *Veri Ön İŞleme ve Öznitelik MühendisliğİNİN Yapay Zekâ Yöntemlerine Uygulanması*, pages 33–54. 06 2023.
- [19] Emrah Gürlek, Fadime Akdeniz, Nada Misk, Reyhan Sahinbas, Uygur Aydın, Çİğdem Erol, and Burcu İlis. *Makine Öğrenmesi Algorİtmaları ile Covid-19 Test Sonuçlarının Tahmin Edilmesi*, pages 353–369. 04 2023.
- [20] Ensar SağbaŞ, Osman Gökalep, and Aybars Ugur. Yüz İfadesi tanıma için mesafe oranlarına dayalı Öznitelik Çıkarımı ve genetik algorİtmalar ile seçimi. 2:19–29, 07 2019.
- [21] Oğuz KAYNAR, Halil ARSLAN, Yasin GÖRMEZ, and Yunus Emre İŞİK. Makine Öğrenmesi ve Öznitelik seçim yöntemleriyle saldırı tespiti. *Bilişim Teknolojileri Dergisi*, 11:175–185, 2018.
- [22] Adem Korkmaz and Selma Bulut. Sahte web sitelerinin sınıflandırma algorİtmaları İle tespit edilmesi. *European Journal of Science and Technology*, pages 826–833, 08 2019.
- [23] Feyyaz KOÇ and Abdulkarim KARABİBER. Makine Öğrenmesi yöntemleri kullanılarak elektrikli cihazların sınıflandırılması. *Türk Doğa ve Fen Dergisi*, 10(1):159–165, 2021.